

김용관 Kim Yong Gwan

디테일이 시스템을 만든다고 믿는 엔지니어.

자기소개

기업의 AI 도입을 **운영 시스템** 으로 만든다. PoC가 아닌 운영까지 — **진단 · 설계 · 구현** 을 한 사람이 책임지는 풀스택 엔지니어. 11일에 5개 LLM 모듈을 묶어 **1유저 71원** 의 비용 모델, **Jetson VRAM** 에 YOLO·LLM 공존, **Flutter → Apple Native NPU** 로 단말 **248ms** 추론까지 — 측정 가능한 도입 의 증거.

경력 / 교육

방송 기술 엔지니어 · 라이브 스트리밍 인프라

· 2년 연속 우수사원 · 라이브 스트리밍 인프라 무중단 운영 및 트러블슈팅

Intel AI For Future Workforce · AI 교육 930시간 수료

· **Python** · Computer Vision (**OpenVINO**) · NLP · Predictive ML · **React**

개인 스터디 · ROS2 · Isaac Sim · 자체 로봇 셋업

· 엔지니어강의 + Yahboom ROSMASTER M1 직접 구축으로 로보틱스 풀체인 학습

핵심 역량

- **디테일이 결정의 품질을 만든다** — 모듈 경계 · 비용 정책 · 검증 환경 분리까지 의사결정 단위로 꼼꼼히 따진다
- **Ollama 헤더를 빼고 llama.cpp 바이너리만** — Jetson VRAM에 YOLO·LLM 공존, 백테스트 환경까지 분리해 답을 만든다
- **측정 가능한 도입** — 1유저 71원·248ms·87.5%↓ 처럼 숫자로 증명 되는 시스템을 만든다
- **PoC가 아닌 운영** — 도메인 정의·DB·BE·Web/App·CI·서브도메인까지 1인이 끝까지 묶는다

CONTACT

email kimi26yg@gmail.com
github github.com/kimi26yg
blog velog.io/@kimi26yg
site portpolio-zeta-three.vercel.app

학력

컴퓨터공학 학점은행제

88 / 140 학점 이수 (2025.11)
2026.08 학위 예정

자격증

- ADsP — 데이터 분석 준전문가
- SQLD — SQL 개발자
- 네트워크관리사 2급

기술 스택 한눈에

AI / ML Python · PyTorch · CoreML · YOLO · OpenCV
· LLM (Anthropic / OpenAI / Gemini) · llama.cpp · Ollama · Quantization · OpenVINO
Backend FastAPI · NestJS · Prisma · PostgreSQL · LangGraph · Docker · Railway
Robotics / Edge ROS2 · Nav2 · SLAM · YDLiDAR · Jetson Orin Nano · Apple Neural Engine
Frontend / App React 19 · Next.js · Vite · Flutter · Expo RN · WebRTC · PWA

REPOS

25 GitHub

CONTRIBUTIONS · 1Y

521 25.11 26.04

FREE-B BACKEND OWNERSHIP

96.0% 119/124 commits

PEAK DAILY COMMITS

102 2026-03-11

superwindsurfer

— 마이크로 인플루언서용 AI 매니저 SaaS · 풀스택 + PWA

콘텐츠 해석 · 광고 분류 · 트렌드 발굴 · 브랜드 검증 4축을 자동화한 AI 매니저 SaaS — 4종 LLM × 3종 캐시로 풀 분석 1유저 71원.

기간	팀 규모	개인 COMMITS	브랜치 운영
2026.04.21 ~ 2026.05.06 (11일)	4인	222 / 350 (63%)	PR 기반 squash · branch protection

PROBLEM

마이크로 인플루언서는 매니저를 고용하기 어렵지만 콘텐츠 해석 · 광고 메일 분류 · 브랜드 검증 · 트렌드 캐치 4가지 일을 매일 직감과 수작업으로 처리한다. 하루 10-30건의 광고 메일에 사기·스팸이 섞이고, 트렌드 탐색에 1-2시간이 든다.

MY ROLE

팀장 / PM · 모듈 3 · 모듈 5 · 인프라 + 운영 어드민 단독. 5개 모듈을 4명이 11일에 총돌 없이 굴리도록 경계와 인프라 를 설계했고, 풀 분석 비용 71원의 비용 모델·캐시 정책 을 잡았다. CI 4종·DB 24마이그레이션·OAuth 토큰 Fernet 암호화·서브도메인 분리까지 단독.

CHALLENGES & RESOLUTIONS

- Q. 4명이 11일에 5개 LLM 파이프라인을 만든다 — 한 모듈만 막혀도 전체가 멈춘다.**
→. 팀 속도의 핵심은 모듈 경계 라고 가정. 그래프 간 직접 호출을 막고 DB 캐시로만 연결. Conventional Commits + branch protection + PR 기반 squash로 변경 흐름을 일원화.
=. 모듈 5개 분리 + 24개 Alembic 마이그레이션. 4명이 11일 총돌 없이 병렬 개발하며 평균 일 31 commits. 본인 222 commits / 전체의 63%.
- Q. 4종 LLM을 무차별 호출하면 1유저 분석에 수백 원이 든다 — 1,000명이면 운영 자체가 불가능.**
→. LLM은 판단·해석에만, 분류·집계는 코드로. 같은 입력은 DB 캐시 + Anthropic Prompt Caching + Early Exit 3종으로 차단. 4종 LLM (Gemini Flash · GPT-4.1-nano · Haiku · Sonnet)을 비용 등급별 라우팅.
=. 풀 분석 1유저 71원, 캐시 히트 시 32%↓. 1,000명 일 1회 운영 추산 213만원/월.
- Q. 트렌드 분석이 '지금' 트렌드는 잘 잡지만, 그때 유행한 두쫌쿠를 과거 시점에서 잡을 수 있는가 는 검증이 안 된다.**
→. 운영 코드와 검증 환경을 물리적으로 분리 + 스냅샷 SHA로 잠그고 타임워프 로 과거 시점을 재현. ground truth 타임라인 JSON으로 회귀 평가.
=. 별도 repo superwindsurfer-backtest 구축 → v3 → v4 회귀 검증 결과로 트렌드 발굴 구조 개편. LLM eval framework의 시작점.

KEY STACK

BACKEND	Python · FastAPI · LangGraph · SQLAlchemy · PostgreSQL · APScheduler
LLM × 4	Gemini Flash · GPT-4.1-nano · Claude Haiku · Sonnet
FRONT / INFRA	React PWA · Vite · Tailwind · Railway · Vercel × 3

IMPACT

1유저 71원	6,645줄	60+ 엔드포인트	222 commits
캐시 히트 시 32%↓	LangGraph 5 그래프	FastAPI · 19 DB 테이블	전체의 63% / 11일

LINKS

live app.superwindsurfer.com · superwindsurfer.com · admin.superwindsurfer.com
deck nlp.superwindsurfer.com (NLP 발표) · pitch.superwindsurfer.com (Pitch 발표)
repo github.com/superwindsurfer/superwindsurfer (private · 조직 계정)

Marritto — ROS2 + 로컬 LLM 기반 AI 홈 로봇 · 1인 풀스택

AI를 물리 세계로 끌어내린 1인 풀스택 시스템 — Wake Word → 로컬 LLM Tool Calling → ROS2 / Home Assistant.

기간	하드웨어	LLM	VISION
2026.04.09 진행 중 (3주, 1인)	Jetson Orin Nano · ROSMASTER M1	llama.cpp · gemma4-E2B Q4	YOLOv8s · MobileNet v3

PROBLEM

로봇 제어 UI는 투박하고, 스마트홈은 따로 놀며, 카메라 모니터링은 수동이다. **집 안의 로봇·IoT·카메라·LLM을 모바일 PWA 한 화면에서 자연어로 통합 제어.** 외출 중 반려묘 모니터링·푸시 알림(CatWatch)까지 같은 시스템 안에서 처리한다.

MY ROLE

Full-stack & Robotics — 1인 단독. ROS2 노드 묶음 → FastAPI 백엔드 → React 19 PWA → Service Worker · Web Push (VAPID/APNs) 까지 3주에 9 메인 commit으로 진화. 펌웨어 인접 (STM32 · IMU · EKF) 부터 모바일 PWA UX까지 **수직 풀체인을 한 사람이 잡았다.**

CHALLENGES & RESOLUTIONS

- q. Jetson 7.6GB VRAM에 YOLO·LLM·로봇이 다 올라가야 한다 — 옛지 trade-off 를 어디서 잡나.**
→. 임베디드 환경에 맞춰 모델 헤드를 최소화 하고 양자화 모델 로 내린다. Ollama → llama.cpp 직접 빌드 로 네이티브 tool calling + thermal 관리. YOLO 추론 부하는 OpenVINO 도입 으로 추가 절감을 검증 중.
=. Q4_K_M 양자화 (gemma4-E2B 2GB) + YOLOv8s (87MB) CUDA 시분할 공존. -fit off 직접 디버깅으로 메모리 fit 실패 우회. idle 30분 자동 종료로 thermal·전력 통제.
- q. LLM이 도구 호출을 부정확하게 하면 물리 세계 동작 으로 사고가 난다 — 자연어 명령을 어떻게 안전하게 매핑하나.**
→. OpenAI 표준 tool-calling 을 채택, 로봇·HA·CatWatch를 9개 함수 로 정의. SYSTEM_PROMPT에 방·기기 매핑을 인라인 명시, 다중 라운드(최대 5-10) 결과 재주입으로 의도 검증.
=. robot_move/stop/status · ha_turn_on/off/get_states/set_brightness · cat_status/history 9 도구 안정 호출. 도구 정의만 갈라끼우면 시니어 케어·매장 안내·공장 MES 연동에 그대로 이식.
- q. iOS PWA 의 Web Push 가 안 잡힌다 — manifest · SW · 사용자 제스처 3박자가 동시에 맞아야만 동작.**
→. iOS Safari가 요구하는 조건을 코드로 못 박는다. manifest.json 필수 + SW 루트 서빙 + 알림 권한은 사용자 제스처 핸들러 내부 에서만 요청.
=. VAPID/APNs 푸시 동작. 5분 쿨다운·포그라운드 억제 적용. 외출 중 반려묘 알림이 실시간으로 도착. Tailscale 사설 HTTPS/WSS로 iOS mic/camera 권한 요건 충족.

KEY STACK

ROBOTICS	ROS2 · Nav2 · Cartographer · YDLiDAR · Mecanum
EDGE AI / VOICE	llama.cpp + CUDA · gemma4 Q4 · OpenWakeWord · Silero VAD · Cohere STT · edge-tts
WEB	FastAPI · React PWA · Service Worker · Web Push (VAPID)

IMPACT

9 commits / 3주 1인 수직 풀체인	9 도구 매핑 LLM ↔ 물리 세계	VRAM 공존 YOLO + gemma4 안정	Day 0 리팩터 monolith → routers
-----------------------------	------------------------	-----------------------------	---------------------------------

LINKS

repo github.com/kimi26yg/marritto (private)
blog vlog.io/@kimi26yg — Marritto 회고 + CatWatch Phase 1·2 글 3편
demo Tailscale 사설 HTTPS — 데모 영상/스크린 별도 제공

Garim · 가림

— 영상통화 딥페이크 온디바이스 탐지 앱 · iOS Native

영상통화 딥페이크를 단말 안에서 잡는 **온디바이스 AI 앱** — CNN+FFT 90/10 하이브리드로 **248ms**, 클라우드 추론을 단말 단가로.

기간	팀 규모	개인 단독 REPO	NATIVE
2026.01.21 ~ 2026.02.03 (14일)	4인 (앱·웹 클라이언트 본인 단독)	4 repo · 33 commits	Swift · CoreML · Apple NPU

PROBLEM

영상통화 기반 딥페이크 금융 사기·신원 사칭이 빠르게 늘지만, 서버 추론은 **영상 데이터 외부 송신** 이 필수라 프라이버시 충돌이 크고 비용도 높다. Garim은 **영상통화 프레임**을 단말 안에서 **248ms**에 검증 해 외부 송신 없이 진위를 가린다.

MY ROLE

App & Web Client 총괄. garim_eye_v2 (Flutter 본체) · garim_attack (Flutter Web 공격자 콘솔) · garim-signaling-server (전화번호 broker) · Garim (랜딩) — **4 repo의 모든 commit이 본인 단독.** 4인 팀에서 모델 학습 / FFT 점수 설계는 팀원이, **코드 통합 · iOS Native · WebRTC · 시그널링 · 랜딩** 은 본인이 잡았다.

CHALLENGES & RESOLUTIONS

- 01** **q.** Flutter 단일로는 영상 프레임 → AI 추론 zero-copy 파이프라인 한계 — 250ms 안에 못 들어온다.
→. 첫 프로젝트지만 단일 스택을 고집하지 않는다. Apple Native (Swift · AVFoundation · Vision · vImage · CoreML) 로 frame sink 부터 추론까지 직접 구성, 연산을 NPU(Neural Engine)에 할당. Flutter는 UI · 네트워크 · 시그널링 담당하는 하이브리드 아키텍처 로 전환.
=. iPhone 12 Pro Neural Engine **248ms 측정.** CPU 650ms → NE 250ms (2.6×). vImage 전처리 **70ms → 2ms (35×).** 메모리 +87MB · 1시간 통화 배터리 ≤15%.
- 02** **q.** 클라우드 추론은 영상 데이터를 외부 송신 — 프라이버시 충돌 + 비용 폭주. 서비스 신뢰 자체가 흔들린다.
→. 추론을 100% 단말 로 내린다. 시그널링 서버는 SDP / ICE / 전화번호 라우팅 만 broker. Int8 양자화 로 모델을 12MB까지 압축해 단말 부담을 낮춘다.
=. 모델 **48 → 12MB (75%↓)**, 정확도 **88.97%** (양자화 손실 1.39%p). eKYC · 콜센터 영상상담 · 콘텐츠 검수 도메인에 그대로 이식 가능한 reference architecture.
- 03** **q.** 상시 추론은 발열·배터리가 무너지고, 정적 주기는 사뿐 필터로 FFT를 우회하는 적대적 공격 에 취약.
→. FFT 화질 신호 를 메타데이터로 사용해 추론 주기를 동적 으로 결정. 의심 정황엔 Variance Penalty로 우회 차단. 자체 적대 시뮬레이터 (garim_attack)로 검증.
=. Adaptive Interval **10s → 5s → 1.25s** 자동 전환 → AI 연산 **87.5%↓**. 최근 20프레임 분산 비정상 시 FFT 점수 50% 페널티. E2E 5케이스 전부 PASS.

KEY STACK

APP	Flutter · Riverpod · go_router · WebRTC
IOS NATIVE	Swift · AVFoundation · Vision · vImage · CoreML Int8
SERVER / WEB	Node.js · Socket.IO (전화번호 broker) · Python · InsightFace (적대 시뮬) · React (랜딩)

IMPACT

248ms iPhone12 NE 측정	88.97% Int8 양자화 후	87.5%↓ Adaptive AI 연산	48→12MB 모델 75%↓
--------------------------------	-----------------------------	---------------------------------	---------------------------

LINKS

live [garim.vercel.app](#) (통합 랜딩)
repo [github.com/kimi26yg/Garim](#) · garim_eye_v2 · garim_attack · garim-signaling-server
demo [Garim_demo.mp4](#) — 시연 영상 별도 제공

Free-B

— 프리랜서 강사 운영 자동화 OS · 강사 앱 + 운영자 어드민

운영자가 묻기 전에 상태가 먼저 보이는 강사 운영 OS — 매칭 · 전자계약 · GPS 체크인 · AI 브리핑.

기간	팀 규모	BACKEND 단독	PM
2026.03.03 ~ 2026.03.13 (11일)	4인 (웹·앱·BE 분담)	119/124 commits (96.0%)	발표 슬라이드 01-03 직접 담당

PROBLEM

> “매일 아침, 강사가 올지 확인하는 전화를 합니다.” — 발표 슬라이드 01

배정 · 계약 · 체크인이 다른 채널에 흩어지면서 운영자는 매번 직접 확인 하고 강사는 다른 정보 환경 에서 수업을 경험한다. **연락 빈도가 아니라 상태 가시성이 진짜 문제**였다.

MY ROLE

PM · Backend 아키텍처 총괄 — 단독. NestJS 14모듈 · Prisma 23모델 · 15 마이그레이션 · 5단계 계약 상태머신 · GPS ActivityLog · AI 운영 브리핑 모두 단독 설계·구현. 발표 PM 파트(슬라이드 01 03) 담당하며 도메인 정의를 팀에 전파.

CHALLENGES & RESOLUTIONS

- Q. 백엔드 개발 경험 0인 상태에서 4인 팀의 백엔드를 혼자 맡는다. 일정 33일, 도메인은 강사 · 계약 · 체크인 3축이 얽힌다.**
→. 기능부터 만들지 않는다. 도메인 모델 먼저, 기능은 나중. NestJS 모듈을 도메인 단위로 14개 분리하고, Prisma 스키마를 마이그레이션을 결정의 흔적 으로 단계별 확장.
=. Prisma 23 모델 / 22 enum / 15 마이그레이션 단독 설계. Backend 119/124 commits (96.0%). PR 7건 전건 머지. 첫 백엔드 프로젝트에서 도메인-주도 구조를 끝까지 끌고 갔다.
- Q. 확인 전화를 없애려면 단순 알림 자동화로는 부족 — 운영자와 강사가 서로 다른 정보 환경 에 있는 게 진짜 문제.**
→. 기능 자동화가 아니라 상태 전이의 연결 을 먼저 설계. 배정 → 계약 → 체크인을 한 흐름으로 묶고 AI는 그 위에서 추천 · 요약 · 알림만 제공.
=. 5단계 계약 상태머신 (DRAFT→SENT→INSTRUCTOR_SIGNED→FULLY_SIGNED→VOID) + GPS ActivityLog (idempotency · ipHash · requestId) + 5분 캐시 AI 운영 브리핑. 상태 가시성 OS 로 동작.
- Q. 외부 계약서(종이 · 타사 PDF)가 재입력 되어야 시스템에 들어온다 — 운영자 시간이 거기서 다 샌다. + AI 비용·PII는 어디서 막나.**
→. 온디바이스 OCR 로 모바일에서 즉시 인식, DocumentDraft 단계 를 뒤 사람 검수를 거친 뒤 등록. AI 운영 브리핑은 5분 캐시 + fallback 우선 + PII 송신 금지 의 의도된 설계 로 비용·보안을 사전에 막는다.
=. MLKit text-recognition + UploadedDocument → DocumentDraft → DocumentImportEvent 파이프라인. AI 호출당 0.51원 추정, 회사당 월 수천원 ROI. 외부 수업이 Free-B 내부 도메인 객체 로 흡수.

KEY STACK

BACKEND	NestJS · Prisma · PostgreSQL · JWT · Swagger · pdf-lib · S3 · Socket.IO
WEB 어드민	Next.js · MUI · TanStack Query · FullCalendar
APP / INFRA	Expo RN · MLKit · Railway · Vercel × 3

IMPACT

119/124 Backend 96.0%	23 / 15 Prisma 모델 / 마이그	PR 7/7 전건 머지	Issues 91 본인 76 생성
--------------------------	----------------------------	-----------------	-----------------------

LINKS

live landing-omega-eight-75.vercel.app · presentation-theta-seven.vercel.app · free-b-seven.vercel.app/dashboard
repo github.com/kimi26yg/free-b (private) · freebee-landing · free-b-presentation

Skills · Track Record

— 경력 · 자격 · 작업 원칙 한눈에

지난 6개월 25개 repo · 521 contribution 을 한 화면에 — AX 엔지니어로 일하는 작업 원칙과 함께.

GITHUB 활동 — 2025.11 ~ 2026.04

521

contributions · 1y

25 repo

public + private

265 commits

우선 10 repo · default branch


9 PR · 91 issues

전건 머지 / free-b

102 / day

최고 단일 일자

월별 커밋 분포



스킬 매트릭스

BACKEND / AI PIPELINE

Python · FastAPI · NestJS · Prisma · PostgreSQL · LangGraph · OpenAI Tool Calling · Anthropic Prompt Caching · APScheduler · JWT · Fernet · S3 · Railway

ROBOTICS / NATIVE

ROS2 Humble · Nav2 · Cartographer · YDLiDAR · Mecanum · IMU/EKF · Jetson Orin Nano · **Apple Neural Engine** · Swift / AVFoundation / Vision / vImage · Wyoming Protocol · Home Assistant

AX 작업 원칙 — 4 LINES

- LLM은 판단·해석에만 호출 — 분류·집계는 Python 코드로
- 모듈은 직접 호출 금지, DB 캐시로만 연결 — 팀 병렬화의 전제
- 비용은 다층 캐시 + Early Exit 으로 통제 — 1유저 71원, 32%↓
- 외부 입력은 격리, 검증 환경은 물리 분리 — snapshot SHA 잠금

자격 / 블로그 / 사이트 프로젝트

자격증 — ADsP · SQLD · 네트워크관리사 2급

학력 — 컴퓨터공학 학점은행제 88/140 (2026.08 학위 예정)

AI / ML / EDGE

PyTorch · CoreML · TFLite · YOLO · OpenCV · **Quantization (Int8 / Q4_K_M)** · Multimodal (mmpromj) · Ollama · llama.cpp · **OpenVINO** · Cohere STT · edge-tts

FRONTEND / APP

React 19 · Next.js 16 · Vite · Flutter · Expo RN · WebRTC · Socket.IO · Service Worker · Web Push (VAPID/APNs) · MUI · Tailwind · shadcn/ui

블로그 — velog.io/@kimi26yg

사이트 — portpolio-zeta-three.vercel.app

사이드 — robotics-trend-analyzer (arXiv 자동 분석, 50 commits, BE/FE 브랜치 분리)